

ANALIZA I GENEROWANIE TEKSTU

BAG OF WORDS, WYDŹWIĘK, SIECI LSTM

ZADANIE 1: BAG OF WORDS



Zapoznaj się ze stronami NLTK: <https://www.nltk.org> oraz <https://www.nltk.org/book/> .

Ponadto, na potrzeby tego zadania przejrzyj też poniższe samouczki.

- <https://www.datacamp.com/community/tutorials/text-analytics-beginners-nltk>
- <https://realpython.com/python-nltk-sentiment-analysis/>
- <https://www.geeksforgeeks.org/tokenize-text-using-nltk-python/>
- <https://www.geeksforgeeks.org/removing-stop-words-nltk-python/>
- <https://www.geeksforgeeks.org/python-lemmatization-with-nltk/>

Możesz poszukać innych podobnych tutoriali w internecie.

Punkty do wykonania:

- Wybierz dowolny i niezbyt krótki artykuły z dowolnego portalu angielskojęzycznego (BBC, NBC, Nature lub inne) . Temat artykułu dowolny – może być polityczny, społeczny, naukowy. Skopiuj go (ręcznie) i zapisz w pliku txt.
- Dokonaj tokenizacji dokumentu. Podaj liczbę słów po tym etapie.
- Usuń stop-words z artykułu używając standardowej listy dla słów angielskich. Podaj liczbę słów po tym etapie.
- Sprawdź czy w naszym zestawie słów (bag of words) są jeszcze jakieś pominięte niepotrzebne słowa. Wówczas dodaj do listy stopwords dodatkowe słowa ręcznie (np. za pomocą komendy append lub extend). Podaj liczbę słów po tym etapie.
- Dokonaj lematyzacji dokumentu. Jaki lematyzator został wybrany? Alternatywnie: możesz dokonać stemmingu. Podaj liczbę słów po tym etapie.
- Podaj przetworzony dokument w formie wektora zliczającego słowa. Następnie wyświetl na wykresie słupkowym 10 najczęściej występujących słów (oś X: słowa, oś Y: liczba wystąpień słowa w tekście).
- Stwórz chmurę tagów (word cloud) dla Twojego dokumentu. Pomocne linki:
<https://www.datacamp.com/community/tutorials/wordcloud-python>
https://amueller.github.io/word_cloud/
<https://pypi.org/project/wordcloud/>

📖 ZADANIE 2: WYDŹWIĘK RECENZJI

Wykorzystaj paczkę NLTK Vader

(<https://www.nltk.org/modules/nltk/sentiment/vader.html> ,
<https://www.nltk.org/howto/sentiment.html>) do sprawdzenia
jak radzi sobie z analizą opinii/sentymentu. Następnie porównaj
ją z innymi narzędziami wydobywającymi emocje.

a) Wejdź na stronę z hotelami (np. <https://www.booking.com/> ,
<https://www.tripadvisor.com/>) i znajdź jedną pozytywną opinię o
jakimś hotelu i jedną zdecydowanie negatywną. Wybierz opinie w
języku angielskim składające się z przynajmniej kilku zdań. Jeśli
uważasz, że opinie są zbyt neutralne, możesz dodać parę słów
nacechowanych emocjami.


b) Używając narzędzia Vader sprawdź w jakim stopniu obie
opinie są pozytywne (pos), negatywne (neg), neutralne (neu) i jaki
jest wynik zagregowany wszystkich opinii (compound), który
waha się od -1 (negatywny) do 1 (pozytywny).

c) Teraz wykorzystaj inne narzędzia do wydobywania emocji. Przetestuj 3 wybrane z listy poniżej lub własne
znalezione:

- Text2Emotion <https://pypi.org/project/text2emotion/>
- NRClex <https://pypi.org/project/NRClex/>
- EmoTxt / EMTk <https://github.com/collab-uniba/EMTk> https://github.com/collab-uniba/Emotion_and_Polarity_SO
- Emotion English DistilRoBERTa-base <https://huggingface.co/j-hartmann/emotion-english-distilroberta-base>
- TextBlob <https://textblob.readthedocs.io/en/dev/quickstart.html>

Podczas używania narzędzi zwróć uwagę jakie emocje są tagowane.

d) Czy wyniki testów są zgodne z oczekiwaniami?



📖 ZADANIE 3: POBIERANIE POSTÓW

Ważnym czynnikiem w analizie postów jest ich zdobywanie. Szczególnie interesujące są wszelakiej maści posty,
informacje i opinie w mediach społecznościowych: Twitter/X, Facebook, Reddit. Gdyby udało nam się pobrać dużą
bazę danych postów, to można je analizować ze względu na tematykę, emocje, itp. Szczególnie interesujący jest
Twitter/X: ma krótkie posty, zasobne w informacje i opatrzone hasztagami.

Celem tego zadania jest wybranie jednego z portali społecznościowych (Twitter/X, Facebook, Reddit, lub inny) oraz
wybranie narzędzia do automatycznego pobierania postów. Następnie trzeba pobrać 100 postów na wybrany przez
Ciebie temat i pokazać zapisane posty w pliku.

Jakie narzędzie wybrać?

- W pierwszej połowie 2023 roku bardzo dobrym narzędziem do ściągania postów z Twittera i Reddita była
paczka **snscrape**. Niestety po przejęciu Twittera przez E. Muska została ona zablokowana i radzi sobie już tylko
z Redditem. Ludzie nadal zgłaszają, że nie działa dla Twittera, ale developer chyba nie chce jej poprawiać:
<https://github.com/JustAnotherArchivist/snscrape/issues>
- Być może alternatywą dla Twittera będzie paczka **Nitter**. Warto sprawdzić czy zadziała.
- Pojawiają się też jakieś inne nowe narzędzia np. **twscrape** <https://github.com/vladkens/twscrape>

Jeśli nie uda się z Twitterem, wybierz inny portal np. Reddit.

ZADANIE 4: LSTM I GENEROWANIE TEKSTU

Wykonaj następujące polecenia związane z sieciami rekurencyjnymi (pliki załączone do wykładu). Zanim to jednak zrobisz, wybierz inną książkę niż analizowana na wykładzie „Alice in Wonderland” (tutaj można ściągnąć plaintext: <https://www.gutenberg.org/>)

- a) Na nowej książce uruchom i przeanalizuj pliki z wykładu o sieciach rekurencyjnych lstm02-04.py (ajlepiej w wersji _pt czyli z pytorchem)
- b) Wytrenuj sieci (lstm02_pt.py i lstm04_pt.py) na 1 epoce, na 5 epokach, na 15 epokach.
- c) Zademonstruj jak działają generatory tekstu (lstm03_pt.py i lstm05_pt.py) po tych treningach. Widać różnice?
- d) Zapisz i pokaż wyniki w pliku tekstowym.