

Algorytm ID3 – wyjaśnienie krok po kroku

Grzegorz Madejski

Poniżej znajduje się tabela z danymi, z których będziemy korzystać jako z przykładu przy wyjaśnianiu działania algorytmu ID3. Można sobie wyobrazić, że sprawdzamy w jakich warunkach pogodowych najlepiej grać w golfa.

Dane przykładowe

Outlook	Temp.	Humidity	Wind	Decision
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No

Zobaczmy **jak działa algorytm ID3 krok po kroku**, używając tej tabeli jako przykładu.

1 Do czego służy ID3

ID3 to algorytm budowy **drzewa decyzyjnego** dla problemów klasyfikacji.

W naszym przykładzie:

- cechy wejściowe to:
 - Outlook
 - Temp.
 - Humidity
 - Wind
- zmienna decyzyjna to:

– `Decision = Yes` albo `No`

Czyli chcemy zbudować reguły typu:

- jeśli `Outlook = Overcast`, to `Decision = Yes`
- jeśli `Outlook = Sunny` i `Humidity = High`, to `Decision = No`
- itd.

ID3 wybiera na każdym kroku **ten atrybut, który najlepiej rozdziela dane**.

2 Intuicja: co znaczy „najlepiej rozdziela dane”

Pytanie: jaki atrybut wybrać jako korzeń drzewa?

Chcemy taki atrybut, po którego podziale:

- grupy są jak najbardziej „czyste”,
- czyli zawierają głównie jedną klasę (`Yes` albo `No`).

Do mierzenia tej „nieuporządkowanej mieszanki” ID3 używa pojęcia:

3 Entropia

Entropia mierzy niepewność / chaos w zbiorze danych.

Dla klasyfikacji binarnej:

$$Entropy(S) = -p_{Yes} \log_2(p_{Yes}) - p_{No} \log_2(p_{No})$$

gdzie:

- p_{Yes} = udział przykładów z klasą `Yes`
- p_{No} = udział przykładów z klasą `No`

Interpretacja

- entropia = **0**, gdy zbiór jest idealnie czysty (same `Yes` albo same `No`)
- entropia jest największa, gdy klasy są wymieszane możliwie najbardziej równomiernie (np. 50% `Yes`, 50% `No`)

4 Najpierw policzmy entropię całego zbioru

W tabeli mamy 14 przykładów.

Policzmy decyzje:

- Yes = 9

- No = 5

Czyli:

$$p_{Yes} = \frac{9}{14}, \quad p_{No} = \frac{5}{14}$$

Entropia całego zbioru:

$$Entropy(S) = -\frac{9}{14} \log_2 \frac{9}{14} - \frac{5}{14} \log_2 \frac{5}{14}$$

W przybliżeniu:

$$Entropy(S) \approx 0.940$$

Co to znaczy?

To oznacza, że nasz zbiór na starcie jest dość niejednorodny: są i Yes, i No.

5 Gain informacyjny

ID3 nie wybiera atrybutu losowo. Liczy dla każdego atrybutu:

Information Gain (Zysk informacji)

To jest spadek entropii po podziale według danego atrybutu.

Wzór:

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

gdzie:

- A = badany atrybut
- v = jedna z jego wartości
- S_v = podzbiór przykładów, dla których atrybut A ma wartość v

Interpretacja

- najpierw mamy chaos całego zbioru,
- potem dzielimy zbiór według atrybutu,
- liczymy średnią ważoną entropię po podziale,
- patrzymy, o ile chaos spadł.

Im większy **gain**, tym lepszy atrybut.

6 Krok 1 ID3: sprawdzamy każdy atrybut

Zbadamy:

- Outlook
- Temp.
- Humidity
- Wind

7 Atrybut Outlook

Możliwe wartości:

- Sunny
- Overcast
- Rain

a) Outlook = Sunny

Wiersze:

1. Sunny, Hot, High, Weak, **No**
2. Sunny, Hot, High, Strong, **No**
3. Sunny, Mild, High, Weak, **No**
4. Sunny, Cool, Normal, Weak, **Yes**
5. Sunny, Mild, Normal, Strong, **Yes**

Zliczenia:

- Yes = 2
- No = 3

Entropia:

$$Entropy(Sunny) = -\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \approx 0.971$$

b) Outlook = Overcast

Wiersze:

3. Overcast, Hot, High, Weak, **Yes**
4. Overcast, Cool, Normal, Strong, **Yes**
5. Overcast, Mild, High, Strong, **Yes**
6. Overcast, Hot, Normal, Weak, **Yes**

Zliczenia:

- **Yes** = 4
- **No** = 0

$$Entropy(Overcast) = 0$$

To zbiór idealnie czysty.

c) Outlook = Rain

Wiersze:

4. Rain, Mild, High, Weak, **Yes**
5. Rain, Cool, Normal, Weak, **Yes**
6. Rain, Cool, Normal, Strong, **No**
7. Rain, Mild, Normal, Weak, **Yes**
8. Rain, Mild, High, Strong, **No**

Zliczenia:

- **Yes** = 3
- **No** = 2

$$Entropy(Rain) = -\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \approx 0.971$$

d) Średnia ważona entropia po podziale przez Outlook

$$\frac{5}{14} \cdot 0.971 + \frac{4}{14} \cdot 0 + \frac{5}{14} \cdot 0.971$$

$$\approx 0.694$$

e) Gain dla Outlook

$$Gain(S, Outlook) = 0.940 - 0.694 = 0.246$$

8 Atrybut Temp.

Możliwe wartości:

- Hot
- Mild
- Cool

a) Hot

Wiersze:

1 *No*, 2 *No*, 3 *Yes*, 13 *Yes*

- Yes = 2
- No = 2

$$Entropy(Hot) = 1.000$$

b) Mild

Wiersze:

4 *Yes*, 8 *No*, 10 *Yes*, 11 *Yes*, 12 *Yes*, 14 *No*

- Yes = 4
- No = 2

$$Entropy(Mild) = -\frac{4}{6} \log_2 \frac{4}{6} - \frac{2}{6} \log_2 \frac{2}{6} \approx 0.918$$

c) Cool

Wiersze:

5 *Yes*, 6 *No*, 7 *Yes*, 9 *Yes*

- Yes = 3
- No = 1

$$Entropy(Cool) = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} \approx 0.811$$

d) Średnia ważona

$$\frac{4}{14} \cdot 1.000 + \frac{6}{14} \cdot 0.918 + \frac{4}{14} \cdot 0.811 \approx 0.911$$

e) Gain

$$Gain(S, Temp.) = 0.940 - 0.911 = 0.029$$

To mały zysk.

9 Atrybut Humidity

Możliwe wartości:

- High
- Normal

a) High

Wiersze:

1 *No*, 2 *No*, 3 *Yes*, 4 *Yes*, 8 *No*, 12 *Yes*, 14 *No*

- Yes = 3
- No = 4

$$Entropy(High) = -\frac{3}{7} \log_2 \frac{3}{7} - \frac{4}{7} \log_2 \frac{4}{7} \approx 0.985$$

b) Normal

Wiersze:

5 *Yes*, 6 *No*, 7 *Yes*, 9 *Yes*, 10 *Yes*, 11 *Yes*, 13 *Yes*

- Yes = 6
- No = 1

$$Entropy(Normal) = -\frac{6}{7} \log_2 \frac{6}{7} - \frac{1}{7} \log_2 \frac{1}{7} \approx 0.592$$

c) Średnia ważona

$$\frac{7}{14} \cdot 0.985 + \frac{7}{14} \cdot 0.592 = 0.789$$

d) Gain

$$Gain(S, Humidity) = 0.940 - 0.789 = 0.151$$

10 Atrybut Wind

Możliwe wartości:

- Weak
- Strong

a) Weak

Wiersze:

1 *No*, 3 *Yes*, 4 *Yes*, 5 *Yes*, 8 *No*, 9 *Yes*, 10 *Yes*, 13 *Yes*

- Yes = 6
- No = 2

$$Entropy(Weak) = -\frac{6}{8} \log_2 \frac{6}{8} - \frac{2}{8} \log_2 \frac{2}{8} \approx 0.811$$

b) Strong

Wiersze:

2 *No*, 6 *No*, 7 *Yes*, 11 *Yes*, 12 *Yes*, 14 *No*

- Yes = 3
- No = 3

$$Entropy(Strong) = 1.000$$

c) Średnia ważona

$$\frac{8}{14} \cdot 0.811 + \frac{6}{14} \cdot 1.000 \approx 0.892$$

d) Gain

$$Gain(S, Wind) = 0.940 - 0.892 = 0.048$$

11 Wybór korzenia drzewa

Porównujemy zyski informacyjne:

- Outlook = **0.246**
- Humidity = **0.151**
- Wind = **0.048**
- Temp. = **0.029**

Największy gain ma **Outlook**, więc:

korzeniem drzewa zostaje Outlook

To pierwszy krok drzewa:

- Outlook = Overcast $\rightarrow$?
- Outlook = Sunny $\rightarrow$?
- Outlook = Rain $\rightarrow$?

12 Rozwijamy każdą gałąź osobno

12.1 Gałąź Outlook = Overcast

Mamy 4 przykłady i wszystkie mają Decision = Yes.

To znaczy, że węzeł jest czysty.

Decyzja:

$$Outlook = Overcast \Rightarrow Yes$$

Nie trzeba już nic liczyć.

12.2 Gałąź Outlook = Sunny

Podzbiór Sunny:

Outlook	Temp.	Humidity	Wind	Decision
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes

W tym podzbiorze:

- Yes = 2
- No = 3

Entropia tej gałęzi to ok. 0.971.

Teraz znowu sprawdzamy, który z **pozostałych atrybutów** najlepiej dzieli ten podzbiór:

- Temp.
- Humidity
- Wind

Sprawdźmy Humidity

Humidity = High

Mamy:

No, No, No

Entropia = 0

Humidity = Normal

Mamy:

Yes, Yes

Entropia = 0

Średnia ważona entropia po takim podziale:

$$\frac{3}{5} \cdot 0 + \frac{2}{5} \cdot 0 = 0$$

Gain:

$$0.971 - 0 = 0.971$$

To idealny podział.

Decyzja dla gałęzi Sunny:

- Sunny + Humidity = High $\rightarrow$ No
- Sunny + Humidity = Normal $\rightarrow$ Yes

12.3 Gałąź Outlook = Rain

Podzbiór Rain:

Outlook	Temp.	Humidity	Wind	Decision
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Rain	Mild	Normal	Weak	Yes
Rain	Mild	High	Strong	No

Tu:

- Yes = 3
- No = 2

Entropia ≈ 0.971

Badamy pozostałe atrybuty:

- Temp.
- Humidity
- Wind

Sprawdźmy Wind

Wind = Weak

Przykłady:

Yes, Yes, Yes

Entropia = 0

Wind = Strong

Przykłady:

No, No

Entropia = 0

Średnia ważona entropia:

$$\frac{3}{5} \cdot 0 + \frac{2}{5} \cdot 0 = 0$$

Gain:

$$0.971 - 0 = 0.971$$

Znowu idealny podział.

Decyzja dla gałęzi Rain:

- Rain + Wind = Weak $\rightarrow$ Yes
- Rain + Wind = Strong $\rightarrow$ No

13 Gotowe drzewo decyzyjne

Ostateczne drzewo wygląda tak:

```
Outlook
|-- Overcast -> Yes
|-- Sunny
| |-- Humidity
| | |-- High -> No
| | '-- Normal -> Yes
'-- Rain
    |-- Wind
    | |-- Weak -> Yes
    | '-- Strong -> No
```

14 Jak czytać to drzewo

To po prostu zestaw reguł decyzyjnych.

Możemy je zapisać jako:

1. Jeśli Outlook = Overcast, to Decision = Yes

2. Jeśli Outlook = Sunny i Humidity = High, to Decision = No
3. Jeśli Outlook = Sunny i Humidity = Normal, to Decision = Yes
4. Jeśli Outlook = Rain i Wind = Weak, to Decision = Yes
5. Jeśli Outlook = Rain i Wind = Strong, to Decision = No

15 Pełny przegląd algorytmu ID3

Teraz zbierzmy całość w jedną procedurę.

Krok 1: Wejście

Dostajemy:

- zbiór przykładów treningowych,
- atrybuty opisujące przykłady,
- klasę decyzyjną.

Krok 2: Sprawdzenie, czy zbiór jest już czysty

Jeśli wszystkie przykłady mają tę samą klasę:

- tworzymy liść z tą klasą,
- kończymy dla tej gałęzi.

Krok 3: Obliczenie entropii aktualnego zbioru

Mierzmy, jak bardzo są wymieszane klasy.

Krok 4: Dla każdego dostępnego atrybutu liczymy Information Gain

Dla każdego atrybutu:

- dzielimy zbiór według jego wartości,
- liczymy entropie powstałych grup,
- wyznaczamy średnią ważoną,
- odejmujemy od entropii aktualnego zbioru.

Krok 5: Wybór najlepszego atrybutu

Wybieramy atrybut o największym gain.

Krok 6: Tworzymy węzeł drzewa

Ten atrybut staje się pytaniem w węźle.

Krok 7: Rekurencja dla każdej wartości atrybutu

Dla każdej gałęzi:

- bierzemy odpowiedni podzbiór danych,
- usuwamy już wykorzystany atrybut,
- powtarzamy procedurę.

Krok 8: Zatrzymanie

Kończymy, gdy:

- zbiór jest czysty,
- nie ma już atrybutów do dalszego podziału,
- albo podzbiór jest pusty.

W praktyce, gdy nie można dalej sensownie dzielić, często zwraca się **klasę większościową**.

16 Co oznaczają te obliczenia intuicyjnie

To najważniejsza część.

Entropia

To miara niepewności.

- Gdy wszystkie przykłady są **Yes**, nie ma niepewności.
- Gdy część to **Yes**, a część **No**, niepewność rośnie.

Information Gain

To odpowiedź na pytanie:

„Jak bardzo znajomość tego atrybutu pomaga przewidzieć klasę?”

Jeśli po rozdzieleniu według atrybutu grupy stają się prawie czyste, to ten atrybut jest bardzo użyteczny.

W naszym przykładzie:

- Outlook daje najlepszy pierwszy podział,
- potem dla Sunny najlepiej działa Humidity,
- a dla Rain najlepiej działa Wind.

Czyli ID3 buduje drzewo, zadając najpierw **najbardziej informacyjne pytania**.

17 Dlaczego ID3 działa rekurencyjnie

Każdy podzbiór danych jest traktowany jak nowy, mniejszy problem.

Na przykład:

- najpierw pytamy o Outlook,
- po wejściu do Sunny ignorujemy już resztę danych spoza tej gałęzi,
- analizujemy tylko przypadki słoneczne,
- szukamy najlepszego następnego pytania **lokalnie dla tej gałęzi**.

To bardzo naturalna strategia „dziel i zwyciężaj”.

18 Zalety ID3

- prosty i intuicyjny,
- łatwo interpretować wynik,
- daje reguły zrozumiałe dla człowieka,
- dobrze działa na danych kategorycznych.

19 Ograniczenia ID3

Warto znać też wady.

1. Preferencja dla atrybutów z wieloma wartościami

Information Gain bywa stronniczy wobec atrybutów o dużej liczbie różnych wartości.

2. Klasyczny ID3 najlepiej działa dla cech dyskretnych

Dla danych ciągłych zwykle trzeba robić progi albo używać rozszerzeń.

3. Łatwo o przeuczenie

Jeśli drzewo rośnie bez ograniczeń, może bardzo dobrze zapamiętać dane treningowe, ale gorzej działać na nowych.

4. Wrażliwość na małe zmiany danych

Niewielka zmiana zbioru może zmienić strukturę drzewa.

20 Co odróżnia ID3 od „zwykłego patrzenia na tabelę”

Człowiek patrząc na tabelę często intuicyjnie zgaduje reguły.

ID3 robi to **formalnie i obiektywnie**:

- mierzy nieuporządkowanie,
- sprawdza każdy możliwy podział,
- wybiera najbardziej informacyjny,
- powtarza procedurę aż do uzyskania czystych liści.

To jest dokładnie systematyczna metoda odkrywania reguł decyzyjnych.